AWS Certified AI Practitioner · AIF-C01

ML 工作流程和 SageMaker



10 階段 ML 工作流程 · 資料準備與訓練 · 調優與 AutoML
部署選項與策略 · Model Monitor · MLOps · 成本優化

今日學習目標

完整的 ML 工作流程	從業務問題定義到迭代改進的 10 個階段
SageMaker 各組件	Studio、Data Wrangler、Feature Store、Autopilot、Experiments
資料準備和特徵工程	資料清理、轉換、特徵儲存與共享
訓練、調優和部署	內建演算法、Spot 訓練、AMT、六種部署選項
模型監控和維護	Model Monitor、資料漂移、MLOps、成本優化

ML 工作流程：10 個階段

1

業務問題定義

目標、成功指標、可行性

Well-Architected

2

資料收集

來源、歷史資料、品質

S3、Glue、Athena

3

資料準備和探索

清理、缺失值、EDA

Data Wrangler

4

特徵工程

選擇、轉換、編碼

Feature Store

5

模型訓練

演算法、切分、交叉驗證

Training Jobs

6

模型評估

指標、混淆矩陣、公平性

Clarify

7

超參數調整

範圍、自動搜索

Automatic Model Tuning

8

模型部署

端點、自動擴展、策略

Endpoints、Serverless

9

監控和維護

性能、漂移、告警

Model Monitor

10

迭代改進

收集新資料、重訓（回到 3）

Pipelines、Registry

SageMaker Studio 家族



SageMaker Studio

完全整合的 ML IDE：統一介面、Notebooks、實驗管理、訓練部署、資料視覺化、團隊協作



Studio Notebooks

完全託管 Jupyter；快速啟動；支援 Python、R、Julia；自動保存與版本控制



Studio Lab（免費）

無需 AWS 帳戶；提供 CPU 與 GPU；最多 15GB 持久儲存；適合學生與研究人員



JumpStart

預訓練模型庫（數百個 FM）、Hugging Face 等開源模型、解決方案模板、一鍵部署、可微調

資料準備：Data Wrangler 與 Processing



SageMaker Data Wrangler

視覺化、無程式碼

- 300+ 內建轉換
- 自動生成資料品質報告
- 來源：S3、Athena、Redshift、Snowflake、JDBC
- 常見轉換：缺失值、One-Hot、標準化

匯入 → 探索與視覺化 → 轉換 → 匯出到 S3 或 Feature Store



SageMaker Processing

大規模、容器化處理

- 支援 Spark、Scikit-learn、自訂容器
- 分散式多實例並行
- 僅在處理期間付費、支援 Spot
- 資料驗證、特徵轉換、模型評估、資料集切分

與訓練和推論深度整合，自動管理基礎設施

SageMaker Feature Store：集中式特徵庫

架構與概念

特徵群組 Feature Group

相關特徵的集合

線上存儲 Online

即時推論、低延遲（DynamoDB 支援）

離線存儲 Offline

訓練與批次分析（S3 + Glue Catalog）

時間旅行 Time Travel

存取歷史時間點的特徵值

最大考點

避免訓練-服務偏差（Training-Serving Skew）：訓練和推論使用相同的特徵計算

其他優勢

- 團隊使用標準化特徵
- 重用已驗證的特徵，加速開發
- 跨團隊和專案共享
- 特徵血緣與審計追蹤，支援合規
- 特徵版本控制與搜尋

訓練選項：內建演算法與更多

SageMaker 內建演算法（無需寫 ML 程式碼，AWS 優化維護）

Linear Learner
分類和迴歸

XGBoost
梯度提升樹、結構化資料

K-Means
聚類

PCA
主成分分析降維

Factorization Machines
推薦系統

Object Detection
物體檢測

Image Classification
圖像分類

Semantic Segmentation
語義分割

Seq2Seq
序列模型如翻譯

BlazingText
文字分類與詞向量

自訂演算法

TensorFlow、PyTorch、MXNet、Scikit-learn；BYOC 完全自訂容器

SageMaker JumpStart

預訓練 FM 與開源模型，快速微調

Marketplace 模型

第三方預訓練模型，訂閱制，專業領域

訓練基礎設施：實例與資料模式

實例	類型	用途
ml.m5	通用型	平衡計算和記憶體
ml.c5	計算優化	CPU 密集訓練
ml.p3 / p4	GPU	深度學習高性能訓練
ml.g4dn	GPU	較便宜的 GPU 選擇
ml.inf1	AWS Inferentia	成本優化推論

選 GPU 前先想：工作負載真的需要嗎？測試時用較小實例

訓練資料模式

File Mode

下載資料到實例本地 EBS

簡單直接，適合小到中型資料集

Pipe Mode

串流資料到訓練實例

啟動更快、省 EBS 成本，適合大型資料集

Fast File Mode

S3 檔案系統，延遲載入

結合兩者優點，無需修改程式碼

分散式訓練與 Managed Spot Training

資料並行 Data Parallelism

分割資料到多個實例，每個實例有完整模型副本

適合大型資料集

模型並行 Model Parallelism

分割模型到多個實例或 GPU

適合超大型模型

支援框架：Horovod、Parameter Server、PyTorch DDP

90%

Managed Spot Training 最多可節省的訓練成本

- 使用 EC2 Spot 實例
- 被回收時自動重試
- 檢查點機制，從中斷處恢復
- 只需在訓練配置中啟用

適用：非緊急、成本敏感、可接受訓練時間變動

Automatic Model Tuning：自動找最佳超參數

隨機搜尋 Random

隨機選擇組合

快速，適合初步探索；不保證最優

網格搜尋 Grid

系統性嘗試所有組合

完整但耗時；適合小範圍

貝葉斯優化 Bayesian

依先前結果智慧選下一組

通常最快找到最優解；推薦

SageMaker 預設

配置要素

- 超參數範圍（搜索空間）
- 優化指標：準確率、F1、AUC、損失
- 最大作業數與並行作業數
- 早停：提前終止表現差的訓練

最佳實踐

- 先粗略搜索再精細調整
- 學習率等參數使用對數尺度
- 限制並行作業數以控制成本
- 監控進度，及時調整策略

SageMaker Autopilot：全自動 AutoML

1. 上傳 CSV、指定目標欄位
2. 分析資料、生成洞察
3. 識別資料品質問題
4. 自動特徵工程
5. 訓練多個候選模型
6. 排名並選出最佳
7. 部署到端點（可選）

運行模式

- Autopilot：完全自動
- Ensembling：多演算法組合
- HPO：只優化超參數（指定演算法）

輸出內容

- 最佳模型與排行榜
- 兩本筆記本：資料探索、候選定義（可編輯）
- 可解釋性報告：特徵重要性

適用場景

- 快速原型、建立基準模型
- 缺乏 ML 專業的團隊
- 結構化資料的分類 / 迴歸

SageMaker Experiments：追蹤與比較實驗

Experiment 實驗

整個 ML 專案或目標｜例：客戶流失預測

Trial 試驗

單次完整訓練執行｜含資料處理、訓練、評估

Trial Component 試驗組件

試驗中的單一步驟｜如某個訓練步驟

自動記錄

- 超參數與指標
- 模型與產物的 S3 位置
- 資料集資訊
- 環境：實例、容器、程式碼版本
- 執行時間與資源消耗

使用優勢

快速找出最佳模型、團隊協作、可重現、符合審計、避免重複實驗

六種部署選項

即時端點 Real-time

毫秒級、持續運行、自動擴展 | 即時推薦、詐欺偵測

批次轉換 Batch Transform

不需常駐端點、結果寫入 S3 | 每日 / 每週批次預測

Serverless 推論

無流量縮到零、按請求付費、有冷啟動 | 間歇流量

非同步推論 Async

最長 15 分鐘、佇列 + S3、SNS 通知 | 大檔案、影片

多模型端點 Multi-Model

單端點託管數千模型、動態載入 | 每用戶一個模型

多容器端點 Multi-Container

串聯多個容器：前處理 + 模型 + 後處理 | 多階段管道

三種部署策略



藍綠部署 Blue/Green

新舊版本同時存在，瞬間切換全部流量；出問題快速回滾；無停機

適用：需要快速部署與回滾



金絲雀部署 Canary

先導小比例流量（如 5%）到新版，監控後逐步 5% → 25% → 50% → 100%

適用：關鍵生產環境、需謹慎部署



A/B 測試

多個版本同時運行並分配流量（如各 50%），比較性能與業務指標

適用：評估模型、優化業務指標

推論優化

模型優化技術

量化 Quantization

降低數值精度（FP32 → INT8），縮小模型、加快推論

剪枝 Pruning

移除不重要的權重和神經元

知識蒸餾 Distillation

以小模型學習大模型的知識



SageMaker Neo

- 編譯模型以優化特定硬體
- 支援 TensorFlow、PyTorch、MXNet、ONNX
- 雲端、邊緣、IoT：一次編譯多平台部署



Elastic Inference（EI）

- 為 CPU 實例附加 GPU 加速
- 不需購買完整 GPU 實例
- 可彈性選擇加速器大小

SageMaker Model Monitor：四種監控



資料品質 Data Quality

與訓練資料的基準統計比對，偵測資料漂移、缺失值、型別變化（平均、標準差、分位數）



模型品質 Model Quality

追蹤準確率、精確率、召回率；需要實際標籤（ground truth），可能有延遲



偏見漂移 Bias Drift

整合 SageMaker Clarify，追蹤 DI、DPL 等公平性指標的變化



特徵歸因漂移

以 SHAP 值追蹤特徵重要性變化，了解決策邏輯的演變

三種資料漂移與應對

協變量漂移 Covariate Shift

輸入特徵分布改變，輸入與輸出的關係不變

例：客戶年齡從 25–35 歲變為 40–50 歲

概念漂移 Concept Drift

輸入與輸出之間的關係改變

例：信用評分標準改變，相同特徵得出不同風險

標籤漂移 Label Shift

輸出標籤的分布改變

例：詐欺案例比例從 1% 增至 5%

偵測方法

統計測試（KS、Chi-square）、分布比較（直方圖、密度圖）、持續監控性能

應對策略

重新訓練、更新特徵工程、調整決策閾值、設定 CloudWatch 告警

MLOps：Pipelines、Model Registry、Projects

SageMaker Pipelines：ML 的 CI/CD 與工作流程編排



步驟類型：ProcessingStep · TrainingStep · TuningStep · ConditionStep · RegisterModel · CreateModelStep

Model Registry

模型版本、血緣追蹤、審批流程、元數據、支援回滾

Pending Approval　Approved

Rejected　Archived

SageMaker Projects

- 預建 MLOps 專案模板
- 整合 CodePipeline、CodeBuild、CodeCommit
- 以 CloudFormation 實現基礎設施即程式碼
- 流程：提交程式碼 → 觸發 Pipeline → 訓練 → 註冊 → 審批 → 部署

成本優化：訓練 vs 推論



訓練成本

- Managed Spot Training：最多省 90%
- 依工作負載選 CPU / GPU，不過度配置
- Pipe Mode 串流資料，減少儲存成本
- 自動停止閒置筆記本（Lifecycle Configuration）
- 增量訓練、檢查點、限制訓練時間



推論成本

- Serverless：間歇流量，無流量不收費
- Batch Transform：非即時，無需常駐端點
- 多模型端點：相似模型共享資源
- Auto Scaling：依流量調整實例數
- SageMaker Neo、量化、剪枝、選小實例

決策指南：需求 → 選擇

毫秒級即時回應	**即時端點**
定期大量處理、不需即時	**Batch Transform**
流量間歇、想省成本	**Serverless 推論**
推論長達 15 分鐘、大檔案	**非同步推論**
大量相似模型（每用戶一個）	**多模型端點**
多階段前後處理管道	**多容器端點**
訓練成本敏感、可接受中斷	**Managed Spot Training**

無 ML 經驗，快速建基準模型	**Autopilot**
自動找最佳超參數	**AMT（貝葉斯）**
避免訓練與推論特徵不一致	**Feature Store**
偵測生產環境的漂移	**Model Monitor**
審批與版本管理	**Model Registry**
自動化端到端 ML 流程	**Pipelines / Projects**
降低新模型上線風險	**金絲雀部署**

考試重點

SageMaker 是最重要的服務之一

熟悉 10 階段流程中每一步的工具

即時 vs 批次 vs Serverless

依延遲需求與流量型態判斷

Feature Store

避免訓練-服務偏差

Model Monitor

監控資料品質與模型品質

Managed Spot Training

節省訓練成本（最多 90%）

Autopilot 與部署策略

AutoML 能力；藍綠、金絲雀

情境練習：該用哪個 SageMaker 功能

1. 業務分析師想不寫程式就清理資料 [redacted]

2. 每晚對 500 萬筆資料做預測 [redacted]

3. SaaS 平台要為每位客戶部署專屬模型 [redacted]

4. 上線後發現客戶年齡分布大幅改變 [redacted]

5. 想用 Spot 實例省下大部分訓練費用 [redacted]

6. 新模型只先開放 5% 流量測試 [redacted]

7. 模型需經審批才能部署到生產環境 [redacted]

8. 大型資料集希望訓練更快啟動 [redacted]

9. 學生想免費、無 AWS 帳戶練習 [redacted]

10. 推論要處理 10 分鐘的影片檔 [redacted]

情境練習：該用哪個 SageMaker 功能

依本日內容整理，先遮住右欄自己作答

1. 業務分析師想不寫程式就清理資料	Data Wrangler
2. 每晚對 500 萬筆資料做預測	Batch Transform
3. SaaS 平台要為每位客戶部署專屬模型	多模型端點
4. 上線後發現客戶年齡分布大幅改變	協變量漂移
5. 想用 Spot 實例省下大部分訓練費用	Managed Spot Training
6. 新模型只先開放 5% 流量測試	金絲雀部署
7. 模型需經審批才能部署到生產環境	Model Registry
8. 大型資料集希望訓練更快啟動	Pipe Mode
9. 學生想免費、無 AWS 帳戶練習	Studio Lab
10. 推論要處理 10 分鐘的影片檔	非同步推論

今日檢查清單

☑ **完整 ML 工作流程**	10 階段：問題定義 → 收集 → 準備 → 特徵 → 訓練 → 評估 → 調優 → 部署 → 監控 → 迭代
☑ **SageMaker Studio**	整合 IDE；Studio Lab 免費；JumpStart 預訓練模型
☑ **資料準備工具**	Data Wrangler 視覺化轉換；Feature Store 集中管理、避免偏差
☑ **內建演算法**	Linear Learner、XGBoost、K-Means、PCA、BlazingText 等
☑ **超參數調整與 Autopilot**	AMT 預設貝葉斯優化；Autopilot 端到端並產生筆記本
☑ **部署選項**	即時、Batch、Serverless、Async、Multi-Model、Multi-Container
☑ **監控與資料漂移**	四種監控；協變量、概念、標籤漂移
☑ **Pipelines 與 MLOps**	Pipelines 編排、Model Registry 審批、Projects 模板
☑ **成本優化**	Spot 訓練省 90%；推論依流量選擇

實踐練習



探索 SageMaker Studio 介面

熟悉 Notebooks、實驗與端點管理位置



使用 JumpStart 部署預訓練模型

體驗一鍵部署與端點測試



了解 SageMaker Pipelines 的範例

觀察處理、訓練、評估、註冊的串接



閱讀 SageMaker 最佳實踐白皮書

整理成本與部署相關建議