AIF-C01 · 內容領域 1

AI 和 ML 的基礎知識

1.1 基本概念與術語 · 1.2 實務使用案例
1.3 AI/ML 開發生命週期

20%

考試計分占比

依 AWS 官方考試指南（AIF-C01）重新整理

領域 1 總覽：任務陳述

1.1

說明基本 AI 概念和術語

術語定義 · AI / ML / GenAI / DL / 代理式 AI 異同 · 推論類型 · 資料類型 · 學習方法

1.2

識別 AI 的實務使用案例

AI 的價值與不適用時機 · 選對技術 · 應用範例 · AWS 託管服務 · 傳統 ML vs FM

1.3

描述 AI/ML 開發生命週期

ML 管道 · FM 來源與使用方式 · 各階段 AWS 服務 · MLOps · 效能與業務指標

基本 AI 術語速查

AI 人工智慧
讓系統模擬人類智慧的最大範疇

ML 機器學習
從資料學習規律，不需寫死規則

深度學習 DL
以多層神經網路學習複雜模式

神經網路
由多層節點組成、模仿神經元的模型

電腦視覺 CV
讓電腦理解圖像與影片

NLP 自然語言處理
讓電腦理解與產生人類語言

模型 vs 演算法
演算法是學習方法；模型是訓練後的產物

訓練 vs 推論
訓練 = 從資料學習；推論 = 用模型做預測

偏差 Bias
系統性誤差或對群體的不公平傾向

公平性 Fairness
對不同群體一視同仁

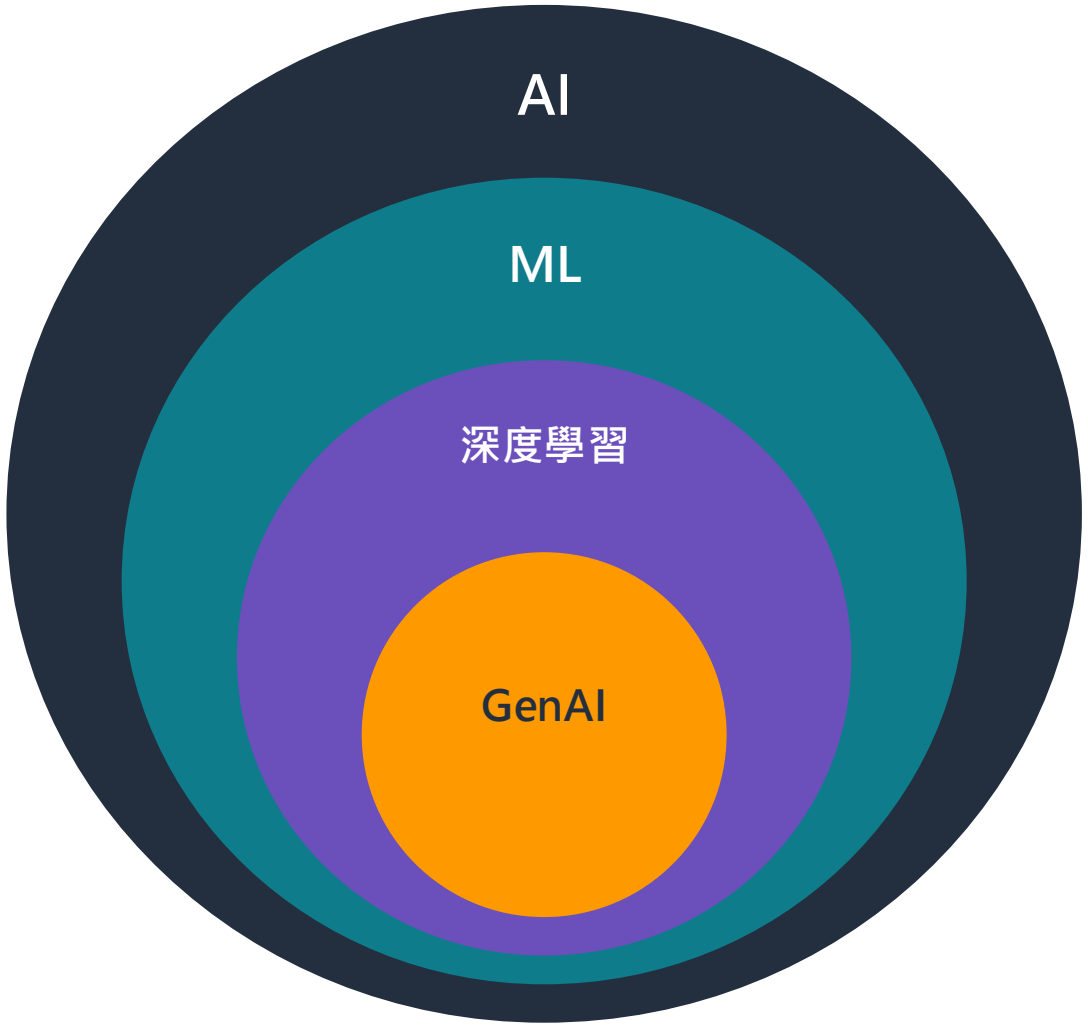
擬合度 Fit
過擬合、欠擬合、恰當擬合

LLM 大型語言模型
以大量文字預訓練的 Transformer 模型

GenAI 生成式 AI
能產生文字、圖像、音訊等新內容

代理式 AI Agentic AI
能規劃、使用工具並自主完成多步驟任務

AI、ML、DL、GenAI、代理式 AI 的關係



AI

最大範疇：模擬人類智慧，含規則式系統

ML

AI 的子集：從資料學習規律

深度學習

ML 的子集：多層神經網路，擅長影像、語音、文字

生成式 AI

多建立在深度學習（Transformer、擴散模型）上，產生新內容

代理式 AI

以 GenAI 為「大腦」，加上規劃、記憶與工具使用，自主完成任務

四種推論類型



即時推理 Real-time

毫秒級回應、端點持續運行。例：詐欺偵測、即時推薦。
SageMaker 即時端點



批量推理 Batch

一次處理大量資料、不需常駐端點。例：每晚產生報表。
SageMaker Batch Transform



非同步推理 Async

請求排隊處理、適合大檔案與長處理時間，完成後通知。
SageMaker 非同步推論



無伺服器推理 Serverless

無流量時縮到零、按用量付費、有冷啟動。適合間歇流量。
SageMaker Serverless

AI 模型中的資料類型

標記資料 Labeled

有正確答案（標籤），用於監督式學習

例：已標記垃圾 / 正常的郵件

未標記資料 Unlabeled

沒有標籤，用於非監督式學習或預訓練

例：大量客戶交易紀錄

表格資料 Tabular

列與欄組成的資料

例：CSV、資料庫表

時間序列 Time series

依時間排序的觀測值

例：每日銷售、感測器讀數

圖像資料 Image

像素組成的視覺資料

例：產品照片、X 光片

文字資料 Text

自然語言內容

例：評論、合約、聊天紀錄

結構化 Structured

有固定格式與欄位

例：表格、關聯式資料庫

非結構化 Unstructured

沒有固定格式

例：圖片、音訊、影片、自由文字

三種學習方法與擬合度

監督式學習

標記資料 | 分類（離散）、迴歸（連續）

無監督學習

未標記資料 | 叢集、降維、異常偵測

強化學習

與環境互動、依獎勵學習策略

過擬合

訓練 98%、測試 65%

正則化、增加資料、簡化模型、交叉驗證、提前停止

欠擬合

訓練 60%、測試 58%

增加模型複雜度、加入特徵、減少正則化、延長訓練

恰當擬合

訓練 92%、測試 90%

兩者都好且接近，泛化能力佳

AI/ML 何時有價值、何時不適用



AI/ML 能提供價值

- 協助人類做決策：從大量資料找出模式
- 解決方案可擴展性：處理人力無法負荷的規模
- 自動化：取代重複性的人工判斷
- 模式複雜、規則難以明確寫出



AI/ML 不適用時

- 成本效益不划算：開發與維運成本高於收益
- 需要確定的結果而非預測：例如固定公式計算
- 資料不足或品質太差
- 法規要求完全可解釋、而模型做不到

依用例選擇 AI/ML 技術

迴歸 Regression

預測連續數值

- 房價、銷售額預測
- 需求預估

常見演算法

線性迴歸、XGBoost

分類 Classification

預測離散類別

- 垃圾郵件偵測
- 詐欺判斷、疾病診斷

常見演算法

邏輯迴歸、決策樹、隨機森林、SVM

叢集 Clustering

把相似資料自動分組（無標籤）

- 客戶分群
- 市場區隔

常見演算法

K-Means

實際 AI 應用範例



電腦視覺

物體偵測、人臉辨識、品質檢測（Rekognition）



NLP

情感分析、實體擷取、分類（Comprehend）



語音識別

會議記錄、字幕（Transcribe）



推薦系統

個人化推薦（Personalize）



詐騙偵測

交易異常、帳戶風險



預測

需求、庫存、財務預測（Forecast）



知識庫

企業文件問答、RAG（Bedrock Knowledge Bases、Kendra）



代理式 AI

自主規劃並執行多步驟任務（Bedrock AgentCore）

AWS 託管 AI/ML 服務

服務	功能	典型情境
Amazon SageMaker AI	完整 ML 平台：建置、訓練、部署	用自有資料訓練客製化模型
Amazon Transcribe	語音轉文字（STT）	會議記錄、影片字幕、客服通話分析
Amazon Translate	神經機器翻譯	多語網站、即時通訊翻譯
Amazon Comprehend	NLP：情感、實體、關鍵詞、PII 偵測	客戶評論分析、文件分類
Amazon Lex	聊天與語音機器人（ASR + NLU）	客服機器人、訂位系統
Amazon Polly	文字轉語音（TTS）	有聲書、語音回覆
延伸：Rekognition / Textract	影像分析 / 文件結構化擷取	人臉辨識 / 發票、表單處理

傳統 ML 還是基礎模型（FM）

	傳統 ML 較適合	基礎模型 FM 較適合
法規考量	需要完整掌控資料與模型	可接受託管服務與供應商條款
可解釋性要求	必須說明每個決策（如信貸審核）	可接受較低的可解釋性
營運限制	低延遲、低成本、邊緣部署	可承擔較高推論成本與延遲
任務型態	結構化資料的預測與分類	文字、圖像生成、摘要、對話
資料量	有足夠的標記資料	標記資料少，靠預訓練知識

AI/ML 管道的組件

1
資料收集
S3、Glue

2
EDA 探索
Data Wrangler

3
資料前處理
Processing

4
特徵工程
Feature Store

5
模型訓練
Training Jobs

6
超參數調校
AMT

7
模型評估
Clarify

8
部署
Endpoints

9
監控
Model Monitor

10
重新訓練
Pipelines

資料準備通常最耗時；監控發現漂移後會重新訓練，形成循環

FM 的來源與生產環境的使用方式

FM 從哪裡來

開源預訓練模型

如 Llama、Mistral，可在 SageMaker JumpStart 或 Bedrock 取得、可自行微調

專有預訓練模型

如 Claude、Amazon Nova，透過 Bedrock API 使用

自行訓練客製化模型

以自有資料從頭訓練，成本與門檻最高

如何在生產環境使用

受管 API 服務

如 Amazon Bedrock：不管基礎設施、按用量付費、上線最快

自我託管 API

如 SageMaker AI 端點或 EC2：自己管實例，掌控度高、維運負擔大

AI/ML 各階段相關的 AWS 服務



Amazon SageMaker AI

建置、訓練、部署與監控 ML 模型的完整平台



Amazon Bedrock

以單一 API 使用多家基礎模型，含知識庫、代理、防護機制



Amazon Q

生成式 AI 助理：Q Business（企業資料問答）、Q Developer（開發協助）



Amazon QuickSight

BI 與資料視覺化，現為 Amazon Quick 的 Quick Sight



Kiro

代理式 IDE：規格驅動開發（需求 → 設計 → 任務），支援 MCP

MLOps 的基礎概念

實驗

系統性追蹤與比較（SageMaker Experiments）

可重複的流程

自動化管道確保每次結果一致（Pipelines）

可擴展的系統

因應資料與流量成長自動擴展

管理技術債務

避免臨時程式碼與手動步驟累積

實現生產整備

測試、審批、版本管理（Model Registry）

模型監控

偵測資料與模型漂移（Model Monitor）

模型重新訓練

效能下降時以新資料自動重訓

模型效能指標：混淆矩陣與分類指標

指標	公式	何時重視
準確率 Accuracy	(TP+TN) ÷ 總數	類別平衡時
精確率 Precision	TP ÷ (TP+FP)	誤報代價高（如垃圾郵件誤刪）
召回率 Recall	TP ÷ (TP+FN)	漏報代價高（如癌症篩檢）
F1 分數	2PR ÷ (P+R)	需平衡精確率與召回率



延伸：迴歸用 MAE、RMSE、R^2；整體區分能力看 ROC-AUC

業務指標：模型好不好，也要看生意



每位用戶成本

服務每位使用者的推論與基礎設施成本



開發成本

建置、訓練、維運的總投入



客戶回饋

滿意度、投訴、採用率



投資報酬率 ROI

(收益 – 成本) ÷ 成本

考點：準確率再高，若每位用戶成本超過收益，專案仍不成功。評估模型要同時看效能指標與業務指標。

情境練習

依官方考試目標整理，先遮住右欄自己作答

1. 預測下個月每家門市的營收	**迴歸**
2. 把客戶依購買行為自動分群	**叢集（無監督）**
3. 每晚對百萬筆資料做預測，不需即時	**批量推理**
4. 流量不穩、想在沒請求時不收費	**無伺服器推理**
5. 稅額依固定公式計算	**不需要 ML**
6. 信貸審核必須能解釋每個決策	**傳統 ML**
7. 把客服通話錄音轉成文字	**Amazon Transcribe**
8. 不想管基礎設施、直接呼叫 FM	**受管 API（Bedrock）**
9. 癌症篩檢最怕漏診	**召回率**
10. 評估 AI 專案是否值得投資	**ROI 等業務指標**

自我檢核：領域 1 官方目標

☑	1.1	**定義基本 AI 術語**	AI、ML、DL、神經網路、CV、NLP、LLM、GenAI、代理式 AI 等
☑	1.1	**比較 AI / ML / GenAI / DL / 代理式 AI**	包含關係與各自特性
☑	1.1	**描述推理類型**	批量、即時、非同步、無伺服器
☑	1.1	**描述資料類型與學習方法**	標記 / 未標記、結構化 / 非結構化；監督、無監督、強化
☑	1.2	**判斷 AI 的價值與不適用時機**	決策協助、擴展、自動化；成本效益、需確定結果
☑	1.2	**選擇合適技術與 AWS 服務**	迴歸、分類、叢集；SageMaker AI、Transcribe、Comprehend 等
☑	1.2	**傳統 ML vs FM**	法規、可解釋性、營運限制
☑	1.3	**描述 ML 管道與 FM 使用方式**	管道組件；開源 / 自訓；受管 API / 自我託管
☑	1.3	**MLOps 與評估指標**	實驗、重現、監控、重訓；效能指標 + 業務指標

下一步

內容領域 2｜GenAI 的基礎知識



Token、嵌入、Transformer、代理式 AI 與 AWS GenAI 服務