AIF-C01 · 內容領域 2

GenAI 的基礎知識

2.1 GenAI 基本概念與代理式 AI · 2.2 能力與限制
2.3 建置 GenAI 應用的 AWS 基礎設施與技術

24%

考試計分占比

依 AWS 官方考試指南（AIF-C01）重新整理

領域 2 總覽：任務陳述

2.1

說明 GenAI 的基本概念

Token、分塊、嵌入、向量、Transformer、FM、多模態、擴散模型 · 使用案例 · FM 生命週期 · Token 定價 · 上下文工程 · 代理式 AI

2.2

了解 GenAI 解決商業問題的能力和限制

優勢 · 缺點（幻覺、非確定性）· 選模型考量 · 業務價值與指標

2.3

描述建置 GenAI 應用的 AWS 基礎設施和技術

Bedrock、SageMaker AI、JumpStart、Amazon Quick、Kiro、Strands Agents、AgentCore · 優勢 · 成本取捨

GenAI 核心概念（一）：從文字到向量

文件	分塊 Chunking	Token 字符	嵌入 Embedding	向量 Vector
原始文字	切成較小段落	模型處理的最小單位	轉成語意向量	存入向量資料庫，以相似度搜尋

Token 字符

文字被切成的單位（字、詞或詞的一部分）。模型的輸入、輸出長度與計費都以 Token 計算

分塊 Chunking

把長文件切成段落，方便嵌入與檢索；塊太大會稀釋語意，太小會失去上下文

嵌入 Embedding

把文字、圖像轉成數字向量，語意相近的內容向量也相近（如 Titan Embeddings）

向量 Vector

嵌入的結果。存在向量資料庫中，透過相似度搜尋找出相關內容，是 RAG 的基礎

GenAI 核心概念（二）：模型家族

基礎模型 FM

以大量未標記資料預訓練、可適應多種下游任務的大型模型；支援 Zero-shot 與 Few-shot

Transformer 型 LLM

以自注意力機制理解上下文、可平行處理整個序列；GPT、Claude、Llama 都屬此類

多模態模型

同時處理文字、圖像、音訊等多種資料，如圖文問答、文件分析

擴散模型 Diffusion

從雜訊逐步「去噪」產生圖像，如 Stable Diffusion、Amazon Nova Canvas

提示工程 Prompt

設計輸入指令以取得更好的輸出（詳見領域 3）

GenAI 的潛在使用案例

影像、影片、音訊產生

行銷素材、產品設計

摘要

長文件、會議紀錄濃縮

AI 助理

企業內部問答、寫作協助

翻譯

多語內容即時轉換

程式碼生成

撰寫、解釋、除錯程式

客戶服務代理

24/7 回覆、處理訂單查詢

搜尋

語意搜尋、企業知識庫

推薦引擎

個人化內容與產品推薦

FM 生命週期

1

資料選擇

選擇與清理大量訓練資料

2

模型選擇

依任務挑選架構或現成 FM

3

預訓練

以大量未標記資料學習通用知識

4

微調

以特定資料調整成專用模型

5

評估

以指標與人工檢驗品質

6

部署

上線提供推論服務

7

回饋

收集使用回饋持續改進

重點：多數企業不會自己預訓練，而是從「模型選擇」開始，直接使用現成 FM，再視需要微調或搭配 RAG。回饋會回到資料選擇，形成循環。

Token 定價與上下文工程

基於 Token 的定價

- 費用 = 輸入 Token 數 × 單價 + 輸出 Token 數 × 單價
- 輸出 Token 通常比輸入貴
- Prompt 越長、回答越長 → 成本越高、延遲越久
- 不同模型單價差異大：小模型便宜快速，大模型能力強但貴
- 省錢做法：精簡 Prompt、限制最大輸出長度、提示詞快取、選擇合適大小的模型

上下文工程 Context Engineering

決定「放進模型上下文視窗的是哪些資訊」，而不只是怎麼寫一句 Prompt

- 系統指令與角色設定
- RAG 檢索到的相關文件
- 對話歷史與長期記憶
- 可用工具的說明與工具回傳結果
- 目標：在有限的上下文視窗內，放入最相關的資訊，兼顧品質、成本與延遲

代理式 AI 的基礎概念

AI 代理 = LLM（推理與規劃）+ 工具（呼叫 API、搜尋、執行程式）+ 記憶（短期與長期）+ 編排（決定下一步）



工具使用 Tool use

代理依任務選擇並呼叫外部工具、API 或資料庫



記憶體管理 Memory

短期記憶保存當次對話；長期記憶跨工作階段保存偏好與事實



工作流編排

拆解任務、決定順序、處理錯誤與重試



多代理系統模式

多個專責代理分工協作：如主管-工作者、圖、群集（swarm）



多代理通訊模式

代理之間傳遞訊息與結果，如 Agent2Agent（A2A）協定



模型上下文協定 MCP

連接代理與外部系統的開放標準（下一頁）

MCP：代理連接外部系統的「USB-C」

MCP Host 主機

AI 應用程式，如 Kiro、Claude、聊天助理

⇄

MCP Client 用戶端

主機內負責與某個伺服器連線的元件

⇄

MCP Server 伺服器

把資料與功能包裝成標準介面，如資料庫、GitHub、內部 API

開放標準

由 Anthropic 提出的開源協定，讓 AI 應用以統一方式連接資料來源、工具與工作流程

為什麼重要

工具只要做成 MCP 伺服器一次，任何支援 MCP 的代理都能使用，不必各自整合

三種能力

Tools（可執行的動作）、Resources（可讀取的資料）、Prompts（可重用的提示範本）

AWS 支援

Bedrock AgentCore Gateway 可把 API 與 Lambda 轉成 MCP 工具；Strands Agents、Kiro 都支援 MCP

GenAI 的優勢與缺點

優勢

適應性	同一模型可處理多種任務
回應能力	即時產生答案
對話能力	自然語言多輪互動
內容生成	快速產出文字、圖像、程式碼

缺點

幻覺	產生看似合理但錯誤的內容
可解釋性低	難以說明為何這樣回答
不準確性	事實或計算可能出錯
非確定性	同樣輸入，每次輸出可能不同

選擇 GenAI 模型的考量因素

模型類型
文字、圖像、多模態、嵌入模型

效能要求
準確度、回應品質

能力
推理、程式碼、多語言、上下文長度

限制
上下文視窗、輸出長度、知識截止

合規性
資料駐留、產業法規、授權條款

成本
Token 單價、佈建輸送量

延遲
即時互動需要快速回應

模型複雜度
越大越強，但越貴越慢

沒有「最好」的模型，只有最符合需求的模型：常是在品質、成本、延遲之間取捨

GenAI 應用的業務價值與指標

跨領域表現

能否在多種任務與部門中發揮效果

投資報酬率 ROI

收益與投入成本的比較

效率

節省的時間與人力

轉換率

使用者完成購買或目標行動的比例

每位使用者平均收入

ARPU，衡量變現能力

準確性

輸出正確、可用的比例

客戶終身價值

CLV，長期帶來的總價值

建置 GenAI 應用的 AWS 服務



Amazon Bedrock

全託管 FM 服務：統一 API 使用多家模型，含知識庫、代理、防護機制、模型評估



Amazon SageMaker AI

完整 ML 平台：自行訓練、微調、部署與監控模型



SageMaker JumpStart

預訓練模型與解決方案範本庫，一鍵部署、可微調



Amazon Quick

代理式工作助理（Quick Suite）：Quick Sight BI、Quick Research、Quick Flows、Quick Automate



Kiro

代理式 IDE / CLI：規格驅動開發，從需求產生設計與任務再寫程式



Strands Agents

AWS 開源的代理 SDK：模型 + 工具 + 提示即可建立代理，支援 MCP 與多代理

Amazon Bedrock AgentCore：讓代理上生產環境

部署與營運 AI 代理的託管平台，可搭配任何框架（Strands、LangGraph、CrewAI）與任何模型

Runtime

無伺服器執行環境，部署與擴展代理，具工作階段隔離

Memory

短期與長期記憶，跨對話保存上下文

Gateway

把 API、Lambda 轉成 MCP 工具，並連接既有 MCP 伺服器

Identity

代理的身分與存取管理，整合既有身分提供者

Policy

以確定性規則限制代理可呼叫的工具與動作

Observability

以 OpenTelemetry 追蹤、除錯與監控代理

Code Interpreter

隔離沙箱中安全執行程式碼

Browser

託管雲端瀏覽器，讓代理操作網頁

Evaluations

自動評估代理與工具的品質

使用 AWS GenAI 服務與基礎設施的好處

AWS GenAI 服務的優勢

協助工具	現成的知識庫、代理、評估工具
降低門檻	不需深厚 ML 專業即可使用 FM
效率與成本效益	不需自建與維運模型基礎設施
上市速度	以 API 快速做出原型與產品
達成業務目標	專注在業務問題而非底層技術

AWS 基礎設施的好處

安全性	加密、IAM、VPC、PrivateLink
合規	多項認證；報告可在 AWS Artifact 取得
責任	共同責任模型清楚劃分職責
安全 Safety	Bedrock 防護機制過濾有害內容

AWS GenAI 服務的成本取捨

取捨面向	說明
基於 Token 的隨需定價	按實際用量付費，適合流量不穩定或初期；用量大時單價較高
佈建輸送量 Provisioned Throughput	預先購買固定吞吐量，效能穩定、適合穩定大量流量；需承諾使用期間
自訂模型	微調或持續預訓練的模型通常需搭配佈建輸送量，訓練與託管都有額外成本
回應速度 vs 成本	更快、更大的模型更貴；小模型便宜但能力較弱
可用性與備援	跨區域推論、多區域部署提高可用性，但成本增加
區域涵蓋範圍	不是每個模型在每個區域都提供；資料駐留需求會限制選擇

Bedrock vs SageMaker AI：怎麼選

	選 Bedrock	選 SageMaker AI
模型來源	現成的 FM	自行訓練或深度客製化
技術門檻	低，只需 API 呼叫	高，需 ML 專業
上線速度	快，立即可用	慢，需訓練時間
客製化程度	中（微調、RAG、代理）	高（完全自訂）
基礎設施	全託管、零維護	需管理訓練與部署資源
典型應用	聊天機器人、內容生成、文件分析	特定業務預測、推薦系統

情境練習

1. 把文件轉成語意向量以便相似度搜尋 [redacted]

2. 產生產品圖片的模型架構 [redacted]

3. 同樣問題每次答案略有不同 [redacted]

4. 讓代理以標準方式連接公司資料庫 [redacted]

5. 多個專責代理分工完成任務 [redacted]

6. 部署代理並管理記憶、身分與工具 [redacted]

7. 用開源 SDK 快速寫出一個代理 [redacted]

8. 從需求自動產生規格與任務再寫程式 [redacted]

9. 流量穩定且大，需保證吞吐量 [redacted]

10. 衡量客服機器人帶來的價值 [redacted]

情境練習

依官方考試目標整理，先遮住右欄自己作答

1. 把文件轉成語意向量以便相似度搜尋	**嵌入 Embedding**
2. 產生產品圖片的模型架構	**擴散模型**
3. 同樣問題每次答案略有不同	**非確定性**
4. 讓代理以標準方式連接公司資料庫	**MCP**
5. 多個專責代理分工完成任務	**多代理系統**
6. 部署代理並管理記憶、身分與工具	**Bedrock AgentCore**
7. 用開源 SDK 快速寫出一個代理	**Strands Agents**
8. 從需求自動產生規格與任務再寫程式	**Kiro**
9. 流量穩定且大，需保證吞吐量	**佈建輸送量**
10. 衡量客服機器人帶來的價值	**效率、轉換率、ROI**

自我檢核：領域 2 官方目標

☑	2.1	**定義 GenAI 基礎概念**	Token、分塊、嵌入、向量、Transformer LLM、FM、多模態、擴散
☑	2.1	**識別 GenAI 使用案例**	影像生成、摘要、助理、翻譯、程式碼、客服、搜尋、推薦
☑	2.1	**描述 FM 生命週期與 Token 定價**	資料 → 模型 → 預訓練 → 微調 → 評估 → 部署 → 回饋
☑	2.1	**上下文工程與代理式 AI**	多代理、MCP、通訊、記憶、工具、編排
☑	2.2	**GenAI 的優勢與缺點**	適應、回應、對話、生成；幻覺、可解釋性、不準確、非確定性
☑	2.2	**選模型考量與業務指標**	類型、效能、合規、成本、延遲；ROI、效率、轉換率、CLV
☑	2.3	**AWS GenAI 服務**	Bedrock、SageMaker AI、JumpStart、Quick、Kiro、Strands、AgentCore
☑	2.3	**AWS 優勢與成本取捨**	降低門檻、上市速度；Token 定價、佈建輸送量、自訂模型

下一步

內容領域 3｜基礎模型的應用

FM 選擇、RAG、提示工程、微調與 FM 評估

