AIF-C01 · 內容領域 3

# 基礎模型的應用

3.1 FM 應用的設計考量 · 3.2 提示詞工程技術
3.3 FM 訓練與微調 · 3.4 評估 FM 效能

28%

考試計分占比

依 AWS 官方考試指南（AIF-C01）重新整理

# 領域 3 總覽：任務陳述

**3.1**

## 描述使用 FM 的應用程式設計考量

FM 選擇準則 · 推論參數 · 客製化成本權衡 · RAG 與知識庫 · 向量資料庫 · AI 代理

**3.2**

## 選擇有效的提示詞工程技術

提示詞結構 · 零 / 單一 / 少樣本與思路鏈 · 最佳實務 · 風險（注入、越獄）· Prompt Management

**3.3**

## 描述 FM 的訓練和微調流程

預訓練、微調、持續預訓練、蒸餾 · 微調方法 · 資料準備與 RLHF

**3.4**

## 描述評估 FM 效能的方法

人工評估、基準資料集、Bedrock 評估 · ROUGE、BLEU、BERTScore、LLM 評審 · 業務指標

# 選擇 FM 的準則

### 成本
Token 單價、託管與客製化成本

### 模態
文字、圖像、音訊、影片、多模態

### 延遲
即時互動需要快速回應的模型

### 多語言支援
是否支援目標語言，例如繁體中文

### 模型大小
參數越多通常越強，但越慢越貴

### 模型複雜度
任務難度是否需要強推理能力

### 自定義能力
是否支援微調、持續預訓練、蒸餾

### 輸入 / 輸出長度
上下文視窗能放多少內容、最多回多少字

### 提示詞快取 Prompt caching
重複使用的長前綴可快取，降低成本與延遲

# 推論參數如何影響回應

## 溫度 Temperature

**控制隨機性**

- 低（如 0–0.3）：穩定、保守，適合事實問答、分類
- 高（如 0.8–1）：多樣、有創意，適合腦力激盪、文案

## Top-p / Top-k

**限制候選詞範圍**

- Top-k：只從機率最高的 k 個詞挑選
- Top-p：只從累積機率達 p 的詞挑選；值越小越保守

## 輸入 / 輸出長度

**最大 Token 數**

- 限制最大輸出長度可控制成本與回應時間
- 設太短會截斷回答；輸入過長可能超出上下文視窗

## 停止序列 Stop sequence

**指定停止點**

- 遇到特定字串就停止生成
- 可控制輸出格式，避免多餘內容

# FM 客製化方式的成本權衡

| 方式 | 做法 | 成本 | 適用情境 |
| --- | --- | --- | --- |
| **情境學習 In-context** | 在提示詞中放指令與範例，不改模型 | 最低 | 快速原型、通用任務 |
| **RAG** | 檢索外部知識放進提示詞 | 中 | 知識常更新、需引用來源 |
| **模型蒸餾 Distillation** | 用大模型（教師）的輸出訓練小模型（學生） | 中 | 要接近大模型品質，但更快更便宜 |
| **微調 Fine-tuning** | 以標記資料調整模型權重 | 高 | 特定風格、格式、領域任務 |
| **持續預訓練** | 以大量未標記領域資料繼續預訓練 | 更高 | 專業領域語言（醫療、法律） |
| **預訓練 Pre-training** | 從頭訓練新模型 | 最高 | 極少數需完全自有模型的情況 |

# RAG 與 Amazon Bedrock 知識庫




## RAG 的商業價值

- 使用最新資訊，不必重新訓練
- 以文件為依據，減少幻覺
- 可附上來源，回答可驗證
- 整合企業私有資料，成本低於微調

## Amazon Bedrock 知識庫

- 連接 S3 等資料來源
- 自動分塊、嵌入與建立索引
- 儲存到向量資料庫並語意檢索
- 與 Bedrock 模型整合，可做 RAG 評估

# 在向量資料庫中儲存嵌入的 AWS 服務



## Amazon OpenSearch Service

搜尋與分析引擎，支援 k-NN 向量搜尋；Bedrock 知識庫最常用的向量儲存（含 Serverless）



## Amazon Aurora

Aurora PostgreSQL 搭配 pgvector 擴充功能，在關聯式資料庫中存向量



## Amazon Neptune

圖形資料庫；Neptune Analytics 支援向量搜尋，可做 GraphRAG



## Amazon RDS for PostgreSQL

同樣透過 pgvector 支援向量儲存與相似度搜尋

# AI 代理的角色與商業應用

**AI 代理能理解目標、規劃步驟、呼叫工具與 API、根據結果調整，自主完成多步驟任務——不只是「回答」，而是「做事」**



## 客服自動化

查詢訂單、處理退貨、更新資料



## 預約與流程處理

查行事曆、預訂、發送確認



## 文件與報告

蒐集資料、分析並產出報告



## 軟體開發

撰寫、測試與修正程式（Kiro）



## 資料分析

查詢資料庫並整理洞察



## IT 營運

監控告警、自動排除故障

# 提示詞的結構

| | |
|---|---|
| 上下文 Context | 背景與角色：「你是一位 AWS 解決方案架構師，客戶是零售業……」 |
| 指令 Instruction | 明確要做的事與格式：「用表格列出 3 個建議，每項不超過 30 字」 |
| 輸入資料 Input | 要處理的內容：客戶需求、文件或問題 |
| 負面提示 Negative prompt | 不要什麼：「不要提到價格」「圖片中不要出現文字」 |

# 提示詞工程技術

## 零樣本 Zero-shot

不給範例，直接下指令。適合簡單、通用任務

## 單一樣本 One-shot

給 1 個範例示範格式

## 少樣本 Few-shot

給 2–5 個範例，讓模型學到模式；適合分類與固定格式

## 思路鏈 Chain-of-Thought

要求逐步推理（「請一步一步思考」）；適合數學與邏輯

## 提示範本 Template

把固定結構做成範本，以變數填入內容，確保一致

# 提示詞工程的好處與最佳實務

### 回應品質改進
清楚的提示詞大幅提升準確與相關性

### 實驗
嘗試不同寫法並比較結果

### 防護機制
在提示詞中設定界線與拒答規則

### 發現
透過測試找出模型的能力與限制

### 特異性和簡潔性
具體明確、去除不必要的文字

### 使用多評論
多次生成或多角度審查後再定稿

**實用口訣：**設定角色 → 給上下文 → 下明確指令 → 指定格式與長度 → 提供範例 → 迭代測試

# 提示詞工程的風險與限制



## 曝險 Exposure

提示詞或回應洩露敏感資料、系統提示詞或內部資訊



## 中毒 Poisoning

在訓練資料或 RAG 文件中植入惡意內容，影響模型輸出



## 劫持 Hijacking

以提示注入覆蓋原本指令，讓模型做出非預期行為



## 越獄 Jailbreak

用角色扮演等技巧繞過安全限制，誘導產生有害內容

**防範：Bedrock 防護機制（提示攻擊過濾）、輸入驗證、最小權限、輸出過濾、人工審核**

# Amazon Bedrock Prompt Management



**集中儲存提示詞**

把提示詞存成可重用資源，不寫死在程式碼中



**版本控制**

每次修改建立版本，可比較與回溯



**變數與範本**

以變數填入不同內容，同一範本多處使用



**測試與比較**

在不同模型與參數下測試同一提示詞



**部署到應用程式**

應用程式直接引用指定版本，更新不必改程式

# 訓練 FM 的關鍵要素

1

## 預先訓練 Pre-training

以海量未標記資料學習通用知識；成本極高，通常由模型供應商完成

2

## 微調 Fine-tuning

以較少量的標記資料調整權重，讓模型擅長特定任務

3

## 持續預先訓練 Continued pre-training

以大量未標記的領域資料繼續預訓練，學會專業領域語言

4

## 蒸餾 Distillation

用大模型的輸出訓練小模型，保留品質、降低成本與延遲

**分辨關鍵：微調用「標記資料」；持續預訓練用「未標記資料」**

# 微調 FM 的方法

## 指令調校 Instruction tuning

以「指令 → 理想回應」配對資料訓練，讓模型更會遵循指令

## 適應特定領域

以醫療、法律、金融等領域資料調整，學會專業術語與寫法

## 轉移學習 Transfer learning

把預訓練學到的知識轉移到新任務，只需少量資料

## 持續預先訓練

以未標記的領域資料延續預訓練，擴充領域知識

# 如何準備微調資料

### 資料策管 Curation

挑選高品質、相關、去重、無錯誤的樣本

### 管控 Governance

確認資料來源、授權、隱私與存取權限

### 大小 Size

資料量要足夠；品質比數量更重要

### 標記 Labeling

提供正確的輸入與期望輸出配對

### 代表性 Representativeness

涵蓋各種情境與族群，避免偏差

### RLHF 人類回饋強化學習

由人類對回應排序，訓練模型更符合人類偏好

**RLHF 流程：**模型產生多個回應 → 人類評分排序 → 訓練獎勵模型 → 以強化學習優化 FM（SageMaker Ground Truth 可蒐集人類回饋）

# 評估 FM 效能的方法



## 真人參與評估 Human-in-the-loop

由人類評分關聯性、風格、品牌語氣等主觀品質



## 基準測試資料集 Benchmark

以標準資料集比較不同模型在相同任務上的表現



## Amazon Bedrock 評估

自動（程式化）評估、人工評估、LLM 評審、RAG 評估

### 程式化評估

準確度、穩健性、毒性等演算法指標

### 人工評估

自有團隊或 AWS 管理的評審

### LLM 評審

以 LLM 評正確性、完整性、有害性

### RAG 評估

檢索相關性與覆蓋率；生成忠實度

# 評估 FM 的指標

| | | | |
|---|---|---|---|
| ROUGE | *Recall-Oriented Understudy for Gisting Evaluation* | 比較生成摘要與參考摘要的重疊字詞，重視召回 | 摘要 |
| BLEU | *Bilingual Evaluation Understudy* | 比較生成譯文與參考譯文的 n-gram 重疊，重視精確 | 翻譯 |
| BERTScore | *以 BERT 嵌入計算語意相似度* | 看「意思」是否相近，而非逐字比對 | 語意相似 |
| LLM 評審 LLM-as-a-judge | *用另一個 LLM 依評分標準打分* | 可評正確性、完整性、語氣、有害性 | 開放式回答 |

# FM 應用的效能評估與業務對齊

## RAG 應用

- 檢索：上下文相關性、覆蓋率
- 生成：忠實度（是否根據文件）、正確性

## 代理應用

- 任務是否完成、工具是否選對
- 步驟數、錯誤與重試次數

## 工作流

- 端到端成功率
- 各步驟延遲與成本

## 對齊業務目標的指標

**任務完成率**

使用者的目標有沒有達成

**使用者滿意度**

評分、回饋、留存

**每次互動成本**

Token 與基礎設施成本

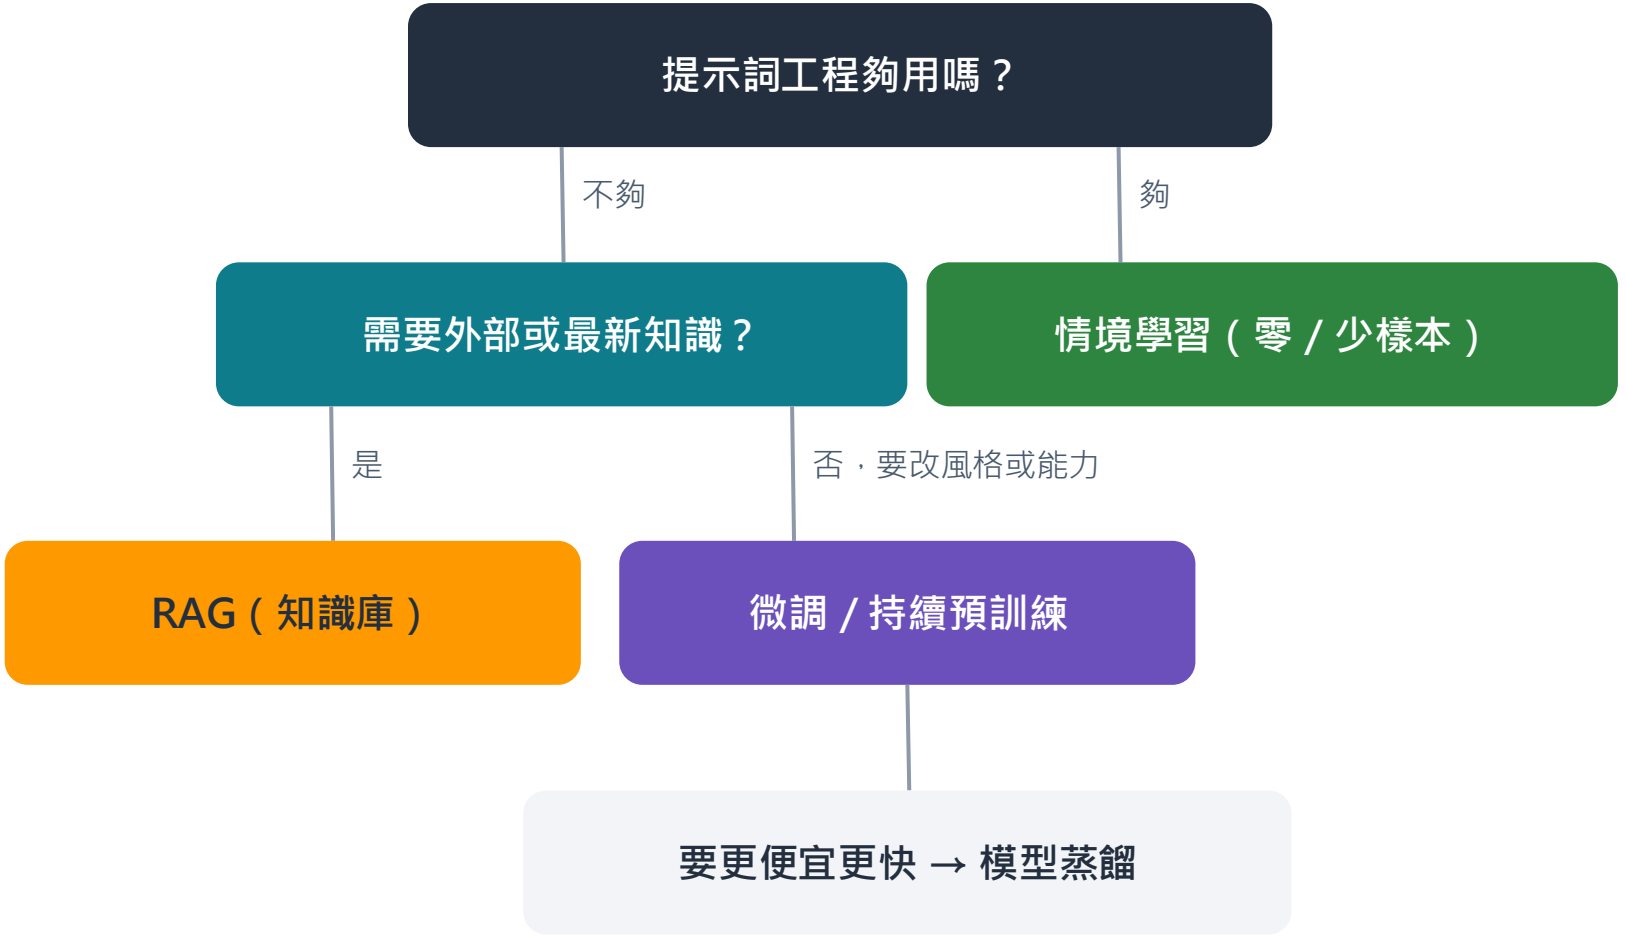
**生產力**

節省的時間與人力

**使用者參與度**

使用頻率與互動深度

# 決策樹：該用哪種客製化


提示詞工程夠用嗎？
不夠
夠
需要外部或最新知識？
情境學習（零 / 少樣本）
是
否，要改風格或能力
RAG（知識庫）
微調 / 持續預訓練
要更便宜更快 → 模型蒸餾

# 情境練習

1. 大量請求共用同一段長系統提示詞 [redacted]

2. 事實問答要穩定、減少隨機性 [redacted]

3. 要大模型品質，但推論更便宜 [redacted]

4. 客服要依每週更新的手冊回答 [redacted]

5. Bedrock 知識庫最常用的向量儲存 [redacted]

6. 給 3 個範例讓格式一致 [redacted]

7. 使用者試圖用指令覆蓋系統提示 [redacted]

8. 提示詞要版本控制並可回溯 [redacted]

9. 評估自動摘要的品質 [redacted]

10. 評估機器翻譯的品質 [redacted]

# 情境練習

*依官方考試目標整理，先遮住右欄自己作答*

| | |
|---|---|
| 1. 大量請求共用同一段長系統提示詞 | **提示詞快取** |
| 2. 事實問答要穩定、減少隨機性 | **降低 Temperature** |
| 3. 要大模型品質，但推論更便宜 | **模型蒸餾** |
| 4. 客服要依每週更新的手冊回答 | **RAG / 知識庫** |
| 5. Bedrock 知識庫最常用的向量儲存 | **OpenSearch Service** |
| 6. 給 3 個範例讓格式一致 | **少樣本 Few-shot** |
| 7. 使用者試圖用指令覆蓋系統提示 | **提示注入 / 劫持** |
| 8. 提示詞要版本控制並可回溯 | **Prompt Management** |
| 9. 評估自動摘要的品質 | **ROUGE** |
| 10. 評估機器翻譯的品質 | **BLEU** |

# 自我檢核：領域 3 官方目標

| | | |
|---|---|---|
| ☑ | 3.1 **FM 選擇準則與推論參數** | 成本、模態、延遲、多語、大小、長度、提示詞快取；溫度 |
| ☑ | 3.1 **客製化成本權衡** | 預訓練、微調、情境學習、RAG、蒸餾 |
| ☑ | 3.1 **RAG、向量資料庫與 AI 代理** | Bedrock 知識庫；OpenSearch、Aurora、Neptune、RDS PostgreSQL |
| ☑ | 3.2 **提示詞結構與技術** | 上下文、指令、負面提示；零 / 單一 / 少樣本、思路鏈、範本 |
| ☑ | 3.2 **最佳實務與風險** | 特異性、實驗、防護；曝險、中毒、劫持、越獄 |
| ☑ | 3.2 **Prompt Management** | 版本控制與管理策略 |
| ☑ | 3.3 **訓練要素與微調方法** | 預訓練、微調、持續預訓練、蒸餾；指令調校、領域適應、轉移學習 |
| ☑ | 3.3 **微調資料準備** | 策管、管控、大小、標記、代表性、RLHF |
| ☑ | 3.4 **FM 評估方法與指標** | 人工、基準、Bedrock 評估；ROUGE、BLEU、BERTScore、LLM 評審 |
| ☑ | 3.4 **應用評估與業務對齊** | RAG、代理、工作流；任務完成率、滿意度、每次互動成本 |

下一步

# 內容領域 4｜負責任 AI 的指南

公平、包容、穩健、安全、真實；透明與可解釋

