AIF-C01 · 內容領域 4

負責任 AI 的指南

4.1 負責任 AI 系統的開發

4.2 透明且可解釋的模型

14%

考試計分占比

依 AWS 官方考試指南（AIF-C01）重新整理

領域 4 總覽：任務陳述

4.1

說明負責任 AI 系統的開發

負責任 AI 特徵 · Bedrock 防護機制 · 負責任的模型選擇 · GenAI 法律風險 · 資料集特性 · 偏差影響 · 偵測與監控工具

4.2

認識透明且可解釋模型的重要性

透明 vs 不透明但可解釋 · Model Cards、Clarify、Bedrock 評估 · 安全與透明的取捨 · 以人為本的設計

負責任 AI 的特徵

偏差 Bias

辨識並降低模型對特定群體的系統性偏差

公平 Fairness

對不同群體提供公平的結果與待遇

包容性 Inclusivity

設計時考慮多元使用者，包括少數群體與身心障礙者

穩健性 Robustness

面對雜訊、異常或對抗性輸入時仍能穩定運作

安全性 Safety

避免產生有害內容或造成實際傷害

真實性 Veracity

輸出正確、可信、有事實依據，避免幻覺

用 Amazon Bedrock 防護機制落實負責任 AI

內容過濾 Content filters

仇恨、侮辱、性、暴力、不當行為，以及提示攻擊；強度可設無 / 低 / 中 / 高

拒絕主題 Denied topics

定義不允許討論的主題（如投資建議），並自訂拒絕訊息

字詞過濾 Word filters

封鎖褻瀆字詞與企業自訂的敏感詞

敏感資訊過濾

偵測並遮罩或封鎖 PII（姓名、電話、信用卡），可加自訂正則表達式

情境接地檢查 Contextual grounding

檢查回應是否根據來源資料、是否與問題相關，偵測幻覺

自動推理檢查 Automated Reasoning

以邏輯規則驗證回應是否符合政策，提升真實性

負責任的模型選擇與 GenAI 法律風險

負責任的模型選擇

- 環境考量：大模型訓練與推論耗能高
- 永續性：能用小模型就不用大模型
- 選擇高效硬體（如 Inferentia、Trainium）與受管服務
- 重用預訓練模型，避免從頭訓練

使用 GenAI 的法律風險

知識產權侵權索賠	輸出可能與受版權保護的內容相似
模型輸出偏見	歧視性輸出引發法律與聲譽問題
客戶信任流失	錯誤或不當回應損害品牌
終端使用者風險	使用者依錯誤建議行動而受損
幻覺	編造事實、引用或數據

資料集的特性與偏差的影響

好的資料集應具備

包容性

涵蓋不同群體與情境

多樣性

來源、格式、族群多元

策管資料來源

可信、合法、經過審查

平衡資料集

各類別、各群體比例合理

偏差的來源與影響

資料偏見

歷史、代表性、測量偏見

演算法偏見

目標設定、特徵選擇偏差

人為偏見

標記主觀、確認偏誤

影響

- 對人口統計群組不公平（如特定族群被拒絕貸款）
- 整體預測不準確
- 過度擬合：只學到偏頗資料的雜訊
- 擬合度不足：沒學到少數群體的模式

偵測與監控偏差、可信度與真實性的工具

分析標籤品質

檢查標記是否一致、正確、有無偏差

人力稽核

由人工抽查輸出與決策

子群組分析

分別評估不同群體的模型表現

SageMaker Clarify

訓練前後偏差偵測（CI、DPL、DI）與 SHAP 可解釋性

SageMaker Model Monitor

在生產環境持續監控偏差漂移與特徵歸因漂移

Amazon A2I

低信心預測交由人工審核的工作流程

SageMaker Clarify 偏差指標

CI	**類別不平衡**	不同群組在資料中的樣本比例差異（訓練前）
DPL	**標籤比例差異**	不同群組正面標籤比例的差（訓練前）；越接近 0 越公平
DI	**差異影響**	群組間正面結果比例的「比值」；1 為公平，常用 0.8 門檻
SHAP	**特徵歸因**	每個特徵對預測的貢獻；用於可解釋性與特徵歸因漂移

透明且可解釋 vs 不透明但可解釋

透明且可解釋

白箱模型：內部邏輯本身就看得懂

- 線性迴歸：係數直接顯示影響
- 決策樹：if-then 規則清晰
- 規則式模型：人類可讀

可解釋性高，但通常較難處理複雜任務

不透明但可解釋

黑箱模型：內部難懂，但可用工具事後解釋

- 深度神經網路、大型語言模型
- 以 SHAP、LIME 解釋單一或整體預測
- 以特徵重要性、部分依賴圖說明

效能高，但解釋是近似、需額外工具

識別透明且可解釋模型的工具



SageMaker Model Cards

記錄模型用途、訓練資料、評估結果、風險與限制的標準化文件



SageMaker Clarify

以 SHAP 計算特徵重要性，提供全局與局部解釋



Amazon Bedrock 模型評估

比較模型的正確性、穩健性、有害性等，作為選模依據



開源模型、資料與授權

公開權重、訓練資料與授權條款，可檢視與稽核

模型安全性與透明度的取捨

1

可解釋性 vs 效能

簡單透明的模型容易解釋，但準確度可能較低；複雜模型效能高但較難解釋

2

透明度 vs 安全性

公開過多模型細節或訓練資料，可能被用來攻擊模型或洩露敏感資訊

3

如何衡量

同時量測可解釋性（如 SHAP 一致性）與效能指標，依業務風險找平衡

判斷原則：決策影響越大（醫療、信貸、司法），越需要透明與可解釋；低風險場景可優先效能。

可解釋 AI 的以人為本設計原則

使用者回饋機制	讓使用者能回報錯誤、評分回應，持續改進模型
AI 決策透明度	告知使用者正在與 AI 互動，並說明決策理由
保留人類控制權	關鍵決策由人類確認，可覆蓋 AI 判斷（Human in the loop）
易懂的解釋	以使用者能理解的語言呈現原因，而非技術細節
揭露限制與不確定性	說明模型的適用範圍與信心程度

SHAP vs LIME

SHAP

以博弈論 Shapley 值計算每個特徵的貢獻

- 適用任何模型
- 提供全局與局部解釋
- SageMaker Clarify 使用

LIME

以簡單模型在單一預測附近近似複雜模型

- 適用任何模型
- 重點在局部、單筆解釋
- 快速直觀，適合圖像與文字

情境練習

1. 聊天機器人不得提供投資建議 [redacted]
2. 回應中的信用卡號要自動遮罩 [redacted]
3. 檢查回應是否根據來源文件 [redacted]
4. 訓練前檢查資料是否偏向某性別 [redacted]
5. 上線後持續監控偏差漂移 [redacted]
6. 低信心的辨識結果交人工確認 [redacted]
7. 記錄自家模型的用途與限制 [redacted]
8. 信貸決策必須完整解釋 [redacted]
9. 為降低耗能改用較小模型 [redacted]
10. 生成圖像疑似侵犯版權 [redacted]

情境練習

依官方考試目標整理，先遮住右欄自己作答

1. 聊天機器人不得提供投資建議	**防護機制：拒絕主題**
2. 回應中的信用卡號要自動遮罩	**防護機制：敏感資訊過濾**
3. 檢查回應是否根據來源文件	**情境接地檢查**
4. 訓練前檢查資料是否偏向某性別	**SageMaker Clarify**
5. 上線後持續監控偏差漂移	**SageMaker Model Monitor**
6. 低信心的辨識結果交人工確認	**Amazon A2I**
7. 記錄自家模型的用途與限制	**SageMaker Model Cards**
8. 信貸決策必須完整解釋	**透明且可解釋的模型**
9. 為降低耗能改用較小模型	**負責任的模型選擇**
10. 生成圖像疑似侵犯版權	**知識產權風險**

自我檢核：領域 4 官方目標

☑	4.1 **負責任 AI 的特徵**	偏差、公平、包容性、穩健性、安全性、真實性
☑	4.1 **用工具識別特徵**	Amazon Bedrock 防護機制
☑	4.1 **負責任的模型選擇**	環境考量、永續性
☑	4.1 **GenAI 法律風險**	智慧財產權、輸出偏見、信任流失、終端使用者風險、幻覺
☑	4.1 **資料集特性與偏差影響**	包容、多樣、策管、平衡；群體影響、不準確、過擬合、欠擬合
☑	4.1 **偵測與監控工具**	標籤品質、人力稽核、子群組分析、Clarify、Model Monitor、A2I
☑	4.2 **透明 vs 不透明但可解釋**	白箱模型 vs 黑箱模型加事後解釋
☑	4.2 **透明度工具**	Model Cards、Clarify、Bedrock 模型評估、開源模型與授權
☑	4.2 **取捨與以人為本設計**	安全 vs 透明、可解釋性 vs 效能；回饋機制、決策透明

下一步

內容領域 5｜安全、合規與管控



IAM、加密、Macie、PrivateLink、CloudTrail、Config、Audit Manager